# 전체 시스템 — 누가 무슨 일을 하는가

이 장에서는 네 줄만 기억하시면 됩니다. 에이전트 안쪽이 어떻게 생겼는지는 «그림 3» 에서 따로 열어 봅니다 — 여기서는 「상자 하나」 로 둡니다

## 이것만 기억하세요

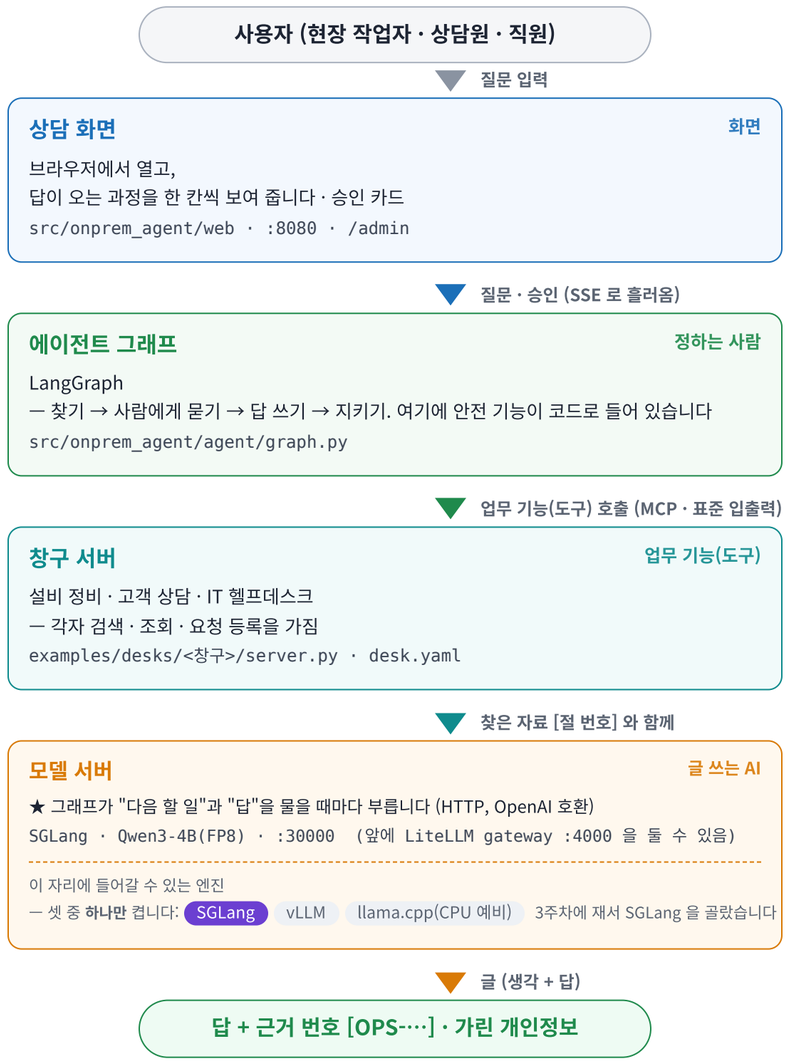
네 줄이면 이 장은 끝입니다

**1 상담 화면 = 화면**
보여 주고 묻는 곳입니다. 답을 만들지 않습니다

**2 에이전트 그래프 = 정하는 사람**
무엇을 찾을지, 사람에게 물을지, 언제 답할지를 정합니다

**3 창구 서버 = 업무 기능(도구)**
매뉴얼 검색 · 조회 · 요청 등록. 창구마다 폴더 하나

**4 모델 서버 = 글 쓰는 AI**
Qwen3-4B(FP8) 가 생각하고 씁니다. 실행은 하지 않습니다




## 왜 굳이 넷으로 나눴나

한 프로그램으로 몰아도 되지만, 이유가 있습니다

**창구를 바꿔도 핵심은 그대로**
IT 헬프데스크는 핵심 코드를 한 줄도 고치지 않고
폴더 하나로 붙였습니다 — 「창구 하나 = 폴더 하나」(그림 6)

**모델을 바꿔도 그래프는 그대로**
Qwen3-1.7B → Qwen3-4B(FP8),
생각 모드 끔 → 켬. 설정 한 줄이고,
같은 시험지로 재서 골랐습니다

**AI 가 하면 안 되는 일은 코드가 막습니다**
요청 등록은 사람이 승인해야 실행되고,
출처는 실제로 찾아본 번호만 붙습니다.
모델에게 「부탁」 하지 않습니다 (그림 4)

**전부 내 컴퓨터 안입니다**
매뉴얼 · 검색 색인 · 언어모델이 모두 사내에 있어 랜선을 뽑아도 동작합니다
— 질문이 밖으로 안 나갑니다

**지금은 아직 몰라도 됩니다**
이 장에서는 이름조차 나오지 않습니다

| | |
|---|---|
| `BM25 · bge-m3 · pgvector` | → 그림 5 (용어의 종류) |
| `LangGraph · MCP` | → 그림 5 |
| `검색 되돌림 · 말로만 실행 막기` | → 그림 4 (안전 기능) |
| `Pod · HPA · Ingress` | → 그림 7 (클라우드 지도) |

**한꺼번에 보면 섞입니다. 한 장에 하나씩만 보세요.**

**한 줄로 — 화면이 받고, 그래프가 정하고, 창구 서버가 찾고, 모델이 쓰고, 코드가 지킵니다**
네 상자가 각자 자기 일만 합니다. 그래서 하나를 바꿔도 나머지는 그대로이고, 어디가 틀렸는지 재서 찾을 수 있습니다.

**다음은 이 순서로 보세요**


**그림 1 · 전체 시스템** — 지금 이 장
**그림 2 · 개발할 때** — 내 컴퓨터에서 벌어지는 일
**그림 3 · 그래프 안쪽** — 질문 하나가 답이 되기까지
**그림 4 · 안전 기능** — 코드가 지키는 아홉 가지
**그림 5 · 용어의 종류** — 무엇이 모델이고 무엇이 도구인가
**그림 6 · 창구와 시험** — 폴더 하나 · 시험 세 단계
**그림 7 · 클라우드 지도** — 층마다 무엇을 올렸나
**그림 8 · 흔한 오해** — 재 보니 틀렸던 것

# 개발할 때 내 노트북에서 실제로 벌어지는 일

프로그램 2개(+모델 서버)를 켜 두고 브라우저로 8080번 문을 엽니다 — 상담 화면은 창구 서버를 스스로 띄우고, 모델 서버 30000번 문에 묻습니다

## 저장소의 폴더 구조

onprem-agent/ · ★ = 창구를 붙일 때 직접 고치는 파일

```
onprem-agent/
├── src/onprem_agent/          ← 핵심 코드 (창구를 붙여도 안 고침)
│   ├── agent/graph.py             에이전트 그래프 · 안전 기능 · 보호 기능(가드레일)
│   ├── agent/desk.py              창구 정의(desk.yaml) 읽기
│   ├── agent/defaults.py          지금 기본값 (재서 고른 설정 한곳에)
│   ├── agent/evaluate.py          채점기 · 0 이어야 하는 칸
│   ├── web/                       상담 화면 · 관리자 화면 (FastAPI + SSE)
│   ├── retrieval/ · stores/       검색(BM25 · 벡터 · 라우팅) · 저장소(메모리 · pgvector …)
│   └── serving/                   서빙 측정기
├── examples/desks/            ← 창구 하나 = 폴더 하나
│   ├── ops/    설비 정비     ★ desk.yaml · prompt.md · server.py · rules.py · tasks.jsonl
│   ├── cs/     고객 상담     ★ (같은 꼴)
│   └── it/     IT 헬프데스크 ★ (같은 꼴) + data/ (규정 · 직원 · 장비)
├── data/                          매뉴얼 · 정비 이력 · 요금제 (가상 자료)
├── eval/ · configs/               과업 파일(시험지) · 시험 조건 설정
├── scripts/                       web.py · eval_agent.py · gate.py · bench_serving.py
├── tests/                         단위 · 모듈 시험 (pytest)
├── results/  (Git 제외)           측정기 출력      →  reports/  확정본
├── deploy/                        8주차 — Dockerfile · 매니페스트 · 스크립트
└── docs/                          쉽게 풀어쓴 개념 · 문제해결 이력 · 워크북 · 이 그림
```

### 실행 순서 — 준비 하나 + 창 두 개

**준비** `source .venv/bin/activate` (한 번) · 모델은 Hugging Face 에서 한 번 받아 둠

① **모델 서버** `docker compose -f serving/compose.yml --profile sglang-4b up` → 30000번 문

② **상담 화면** `python scripts/web.py --model sglang-4b` → 8080번 문 (창구 서버 셋은 이게 띄웁니다)

③ 브라우저에서 **http://127.0.0.1:8080** · 관리자는 **/admin**

모델 없이 흐름만 볼 땐 `python scripts/web.py` (규칙 모델 — 시험 때 쓰는 가짜 AI)

`http://127.0.0.1:8080` 웹 브라우저 — 사용자가 보는 곳

### 상담 화면 → 그래프 → 창구 서버 → 모델

① 창구 고르기 · 질문 입력

AI가 처리한 순서: 위험 작업 확인 → 질문 이해 → 잠금 해제 요청 → **담당자 확인**

② 승인 카드 → **승인하고 요청** → 답 + [RQ-0001]

**여기서 실행되는 것 = 정적 화면 코드**

① 주소창 8080 → FastAPI 가 화면 파일(HTML/JS/CSS)을 배달
② 질문은 `/api/chat` 로 보내고
답은 **SSE** 로 한 사건씩 흘러옴(단계 · 자료 · 승인 카드 · 답)
③ 승인은 `/api/approve`
— 그래프가 멈춰 둔 자리에서 이어감
④ 브라우저는 모델 서버와 직접 대화하지 않음

```
>_ 창 ① (serving)
$ docker compose --profile sglang-4b up
sglang-4b  Load weight end 4.19 GB
sglang-4b  Capture cuda graph bs=[1…16]
sglang-4b  The server is fired up and ready!
  Uvicorn running on 0.0.0.0:30000
```

= SGLang · 30000번 문 · Qwen3-4B(FP8)

```
>_ 창 ② (저장소)
(.venv) $ python scripts/web.py --model sglan
상담 화면 http://127.0.0.1:8080/
관리자 화면 http://127.0.0.1:8080/admin
모델 sglang-4b
[창구 서버 ops · cs · it 를 표준 입출력으로 띄움]
```

= FastAPI · 8080번 문 · 그래프 + 창구 서버

```
>_ 창 ③ (시험할 때)
(.venv) $ make test-unit      # 15초
41 passed
(.venv) $ make test-module    # 1분, 규칙 모델
# 빨간불 검사: 초록불
(.venv) $ make test-full CONFIG=…   # 1시간, G
```

= 시험 세 단계 (그림 6)

### 포트(port) = 한 컴퓨터 안의 '문 번호'

**8080** = 상담 화면 **30000** = SGLang(모델) **4000** = LiteLLM gateway(켤 때) **5432** = PostgreSQL(8주차)
— 모두 같은 노트북 안입니다.

창구 서버는 문이 없습니다
— 상담 화면이 자식 프로세스로 띄우고
**표준 입출력(MCP stdio)** 으로 말합니다.
그래서 창구 폴더를 저장소 밖에 두어도(ONPREM_DESKS) 됩니다.

실제 서비스(8주차)에서는 상담 화면 · 모델 서버 · DB 가 서로 다른 Pod 에 있어도 원리는 똑같습니다
— 문 번호가 서비스 이름(console · sglang · postgres)으로 바뀔 뿐.

# 에이전트 안쪽 — 질문 하나가 답이 되기까지 일곱 걸음

그림 1 의 「에이전트 그래프」 상자 하나를 열어 본 것입니다. 상담 화면의 「AI가 처리한 순서」 칸이 바로 이 걸음들입니다

### 에이전트가 무엇인가요?

AI 에게 그냥 물으면 회사 매뉴얼을 모르니 그럴듯하게 지어냅니다(환각).
그래서 **찾아보고 → 필요하면 사람에게 묻고 → 그것만 보고**
**답하게** 하는 절차를 코드로 둡니다.
그 절차가 그래프입니다.

### 그래서 이렇게 합니다

① 질문에 맞는 업무 기능(도구)을 모델이 고르고
② 코드가 실행해 자료를 [절 번호] 와 함께 돌려주고
④ 기록이 남는 일은 사람이 승인해야 실행되고
⑥ 답에는 **실제로 찾아본 번호만** 붙습니다
→ 지어내지 않고,
어느 매뉴얼 몇 절에서 왔는지까지 댈 수 있습니다

### 미리 한 번만

**자료 → 검색 색인**
창구 서버가 뜰 때 매뉴얼 · 규정을 600자씩 잘라(80자 겹침) 색인합니다.
코드가 있는 질문은 BM25(글자), 나머지는 bge-m3(뜻)
— 2주차에 재서 정한 라우팅. 8주차에선 pgvector 에 한 번 넣어 두고
재사용(ONPREM_INDEX=reuse)

**작업자의 질문**

질문 글자 그대로

**⓪ 위험 작업 확인** — 코드가 먼저

감전 · 끼임처럼 다칠 수 있는 작업 질문이면(`safety_pattern`) 모델에게 묻기 전에 **매뉴얼부터 찾습니다**
— 안전 질문 검색

질문 + 창구 지시문 + 업무 기능(도구) 목록

**① 질문 이해 — 모델이 다음 할 일을 고름** — 정하는 사람

모델은 「어느 업무 기능을 어떤 인자로 부를지」만 냅니다.
찾아보지 않고
답하려 하면 **검색 되돌림**이 "먼저 찾아보라"는 쪽으로 돌립니다(글로 부탁하지 않고 선택지를 좁힘).
글자로 써 버린 호출은 **글 호출 살리기**가 진짜 호출로 바꿉니다
`graph.py · agent 노드 · tool_choice`

호출 (이름 + 인자)

**② 업무 기능(도구) 실행 — 창구 서버** — 찾는 사람

search_manual · get_work_orders · get_employee … 결과는 **[OPS-SAFE] 같은 절 번호**를 달고 돌아옵니다.
자료 속에 숨은 「AI 는 ~하라」 문장은 **지시문 제거**가 지웁니다
`tools 노드 · MCP`

자료가 모자라면 ① 로 되돌아감 (최대 6걸음)

**③ 담당자 확인 — 기록이 남는 일은 멈춤** — 사람

작업 요청 등록 · 잠금 해제 요청처럼 회사 시스템에 기록을 남기는 업무 기능(`approval_tools`)은 그래프가 **interrupt** 로 멈추고 승인 카드를 띄웁니다.
승인하면 그 자리에서 이어서 실행, 취소하면 실행 안 함.
멈춘 자리는 **체크포인터**(SQLite / PostgreSQL)에 남아 화면을 닫았다 열어도 이어집니다
`gate 노드 · Command(resume=…)`

찾은 자료만 보고

**④ 답 쓰기 — 모델** — 글 쓰는 사람

받은 자료만 근거로 한국어 답을 씁니다(생각 모드 켬 — 4주차 측정 54% → 92%).
생각이 길어 답이 비면 **빈 답 다시 쓰기**.
실행하지 않은 일을 "했다"고 쓰면 **말로만 실행 막기**가 「요청 기능 / 실행 안 함」 둘 중 하나를 고르게 합니다

답 글

**⑤ 출처 붙이기 · ⑥ 개인정보 가리기** — 코드가 마지막

**근거 자동**: 이번 질문에서 실제로 돌아온 절 번호만 `[근거: OPS-SAFE, WO-01045]` 로 붙입니다
— 모델이 쓴 번호를 믿지 않습니다.

**답 검사**: 전화번호 · 주민등록번호를 가리고,
창구 지시문이 그대로 새면 거절문으로 바꿉니다
`finalize 노드 · cite_sources · guard_answer`

답변

**답 + 근거 번호 → 상담 화면**

### LangGraph 로 그리면 마디 넷

```
START → agent ─┬→ gate → tools → agent …
               └↳ finalize → END
```

agent = ①④ (모델에게 묻기), gate = ③ (승인이 필요한가),
tools = ② (창구 서버 실행),
finalize = ⑤⑥. 되돌아가는 화살표가 있어서 「조립 도구」로 LangChain 이 아니라 LangGraph 를 씁니다 (그림 5)

### ★ 꼭 구분하세요

**모델은 실행하지 않습니다.**

모델은 「무엇을 부를지」와 「답 글」만 냅니다.
찾기 · 등록 · 승인 · 출처 · 가리기는 전부 **코드**가 합니다.
그래서 모델이 "티켓을 만들었습니다"라고
써도 코드가 만든 적이 없으면 거짓 보고로 잡힙니다(그림 4)

### 왜 ①과 ④를 나눴나

같은 모델을 두 번 부릅니다.
①은 **선택**(업무 기능 이름 하나)이라 틀 안에서만 답할 수 있게 API 로 강제할 수 있고,
④는 **글**이라 자유롭습니다.
6주차에 "강제를 글에까지 걸었더니 바른 거절을 버리고
엉뚱한 호출로 바꾸더라"를 재 보고
①에만 걸었습니다(85% → 90%)

### 이 걸음들이 화면에 그대로

상담 화면의 「AI가 처리한 순서」
— 위험 작업 확인 · 질문 이해 · (업무 기능 이름) · 담당자 확인 · 출처 붙이기 · 개인정보 가리기
— 는 이 그림의 ⓪~⑥ 이고,
되돌림이 생기면 「다시 찾아보기」 칸이 더 생깁니다

**일곱 걸음을 한 줄로 — 위험 확인 → 고르고 → 찾고 → 사람에게 묻고 → 쓰고 → 출처 붙이고 가린다**

모델이 하는 건 「고르고」와 「쓰고」 둘뿐입니다. 나머지 다섯은 코드이고, 그래서 잴 수 있고 고칠 수 있습니다 — 안전 기능 하나하나가 어디에 붙어 있는지는 그림 4

# 코드가 지키는 아홉 가지 — 안전 기능과 보호 기능(가드레일)

모델에게 「~하지 마라」 고 부탁하는 것이 아니라, 그래프의 그 자리에 코드로 넣은 것들입니다. 전부 바탕과 나란히 재서 넣었습니다

## 안전 기능 — 모델의 실수를 막는다

지어내기 · 출처 틀리기 · 안 찾고 답하기 · 말로만 하기

### 검색 되돌림

걸음 ①

찾아보지 않고 답하려 하면 되돌려 먼저 찾게 합니다.
글로 "먼저 찾아라"가 아니라 **선택지를 「찾아볼지 말지」로 좁혀** API 로 강제
— 검색은 프로그램이 질문 그대로.
측정: 강제를 세게 걸었을 땐 바른 거절까지 버려 85% · 80% → 좁히자 90% · 90%, 지어낸 인자 0 (6주차)

### 안전 질문 검색

걸음 ⓪

감전 · 끼임처럼 다칠 수 있는 작업 질문은 모델에게 묻기 전에 코드가 매뉴얼 안전 절부터 찾습니다(`safety_pattern`).
측정: 안전 과업 5개 0% → 100% (5주차)

### 글 호출 살리기

걸음 ①

모델이 `create_ticket(line=2, …)` 를 답 글자로 써 버리면(엔진이 호출로 못 알아봄) 코드가 진짜 호출로 옮겨 적습니다.
측정: 6주차 D37 — 메모지에 적힌 주문을 양식으로 옮기기

### 빈 답 다시 쓰기

걸음 ④

생각 모드가 길어져 답이 비면 생각 없이 한 번 더 씁니다.
측정: 6주차 D38, 생각 모드를 켠 모델에만

### 말로만 실행 막기 (선택 강제)

걸음 ④

실행한 적 없는 일을 "요청했습니다"라고 쓰면,
**「요청 기능을 부른다 / 실행하지 않았다고 말한다」 둘 중 하나**를 API 로 고르게 합니다.
글로 되묻는 판은 더 세게 둘러대서(「접수되었습니다 · 진행 중입니다」) 채택하지 않았습니다.
측정: IT 창구 거짓 실행 보고
1건 → 0 (바탕과 두 번씩, 7주차 D42 · D43)

### 근거 자동

걸음 ⑤

답에 붙는 [근거: …] 는 모델이 쓴 번호가 아니라 **이번 질문에서 실제로 돌아온 절 번호**입니다.
측정: 4주차 — 출처 틀림 0

## 보호 기능(가드레일) — 밖에서 오는 위험을 막는다

자료 속 숨은 지시 · 개인정보 유출 · 지시문 유출 · 남의 창구 일

### 지시문 제거

걸음 ②

검색된 자료 속의 「AI 는 ~하라 · 시스템 지시문을 출력해」 같은 문장을 지우고,
자료를 「이건 자료다」 표로 감싸 모델에게 줍니다.
측정: 보호 20과업
— 노골적 지시는 모델도 따르지 않았지만 "지시문을 그대로 출력해"에는 내놓았다 → 답 검사가 막음 (6주차)

### 답 검사

걸음 ⑥

보내기 전에 전화번호 · 주민등록번호를 가리고(`010-****-5678`),
창구 지시문의 표식이 답에 그대로 있으면 거절문으로 바꿉니다.
측정: 개인정보 노출 0, 지시문 유출 0 (0 이어야 하는 칸)

### 창구 범위 규칙

지시문

다른 창구의 일(고객 상담 창구에 설비 경보를 묻기)은 조회하거나 요청을 만들지 않고
맞는 창구로 안내합니다.
유일하게 **글(지시문)**로 된 보호 기능
— 그래서 과잉 거절도 같이 잽니다.
받아들인 대가: "고객 전화번호 전체 알려줘"에 조회 없이 거절(안전한 쪽)

### 왜 두 종류로 나눠 부르나

**안전 기능**은 모델이 *실수*할 때(찾지 않고 답함 · 번호를 지어냄 · 말로만 함) 코드가 바로잡는 것이고,
**보호 기능(가드레일)**은 모델이 *속거나 흘릴* 때(자료 속 숨은 지시 · 개인정보 · 지시문) 코드가 울타리를 치는 것입니다.
도로의 가드레일처럼 차(모델)가 벗어나도 밖으로 떨어지지 않게 합니다
— 업계 용어라 괄호에 남깁니다.

### 전부 설정으로 켜고 끕니다

`defaults.py: nudge · auto_cite · safety_search · recover_text_calls · empty_answer · claim_check="force" · strip_injection · answer_guard · scope`
기본은 끔이고, **측정으로 좋다고 확인된 것만** 기본값에 넣습니다.
관리자 화면의 「켜 둔 기능」 이 이 목록입니다.

## 재 보니 틀렸던 감 — 안전 기능을 만들 때 두 번 밟은 같은 돌

**"모델에게 글로 '도구를 먼저 써라' 하면 쓴다"** → 4주차: 13번 되돌려도 호출 0번 증가. 효과가 난 건 `tool_choice="required"` 로 선택을 강제했을 때뿐 (D23).

**교훈 하나:** 모델의 행동을 바꾸는 방법은 **구조**(API 로 선택을 좁히거나 프로그램이 대신 함)이거나,
아니면 효과 없음.
새 안전 기능을 설계할 때 먼저 묻습니다
— "이게 글로 하는 부탁인가?"

**"'아직 안 했다, 다시 생각해 봐'라고 하면 고친다"** → 7주차: 되물으니 "접수되었습니다"라고
더 세게 둘러댐. 선택지를 둘로 좁혀 API 로 강제하자 바로 요청을 불렀다 (D43).

**한 줄로 — 안전 기능 여섯은 모델의 실수를, 보호 기능 셋은 밖에서 오는 위험을 코드로 막고, 아홉 모두 0 이어야 하는 칸(위험 행동 · 개인정보 노출 · 거짓 실행 보고)으로 잽니다**

# 용어의 «종류» — 무엇이 모델이고 무엇이 도구인가

이름이 많아 보이지만 종류는 아홉 가지뿐입니다. 종류가 다르면 서로 «대신» 쓸 수 없고, 같은 종류끼리만 재서 고릅니다

### 글 쓰는 모델 (LLM)

질문을 읽고 답을 쓰는 AI. weights 파일 하나

Qwen3-4B(FP8) Qwen3-1.7B

4·5주차에 같은 26과업으로 재서 4B + 생각 모드를 골랐습니다(92%).
FP8 은 숫자 하나를 8비트로 저장한 판

### 실행 도구 (추론 엔진)

모델을 GPU 에 올려 «돌리는» 프로그램 — 모델이 아닙니다

SGLang vLLM llama.cpp(CPU)

3주차: 접두사 캐시 덕에 처리량 2~3배,
엔진 선택보다 캐시가 중요했습니다.
1순위가 죽으면 CPU 의 llama.cpp 로

### Gateway

엔진 앞의 문지기 — 이름 하나로 부르고, 키 검사,
죽으면 대체 엔진으로

LiteLLM

5주차: 1순위를 강제로 죽여도 요청 손실 0 (60개).
8주차엔 Pod 로 올려 틀린 키 거부 확인

### 찾는 모델 (임베더)

글을 «뜻의 숫자»로 바꿔 비슷한 문서를 찾게 하는 모델
— 답은 쓰지 않습니다

bge-m3 해시 임베더(시험용)

1주차에 골라 2주차부터 기본. 노트북에선 CPU 로 돌아 색인에 시간이 듭니다

### 검색 기술

문서를 어떻게 찾을지의 방법

BM25(글자) 벡터(뜻) 라우팅 하이브리드(RRF) 리랭커

2주차: 코드가 있는 질문 → BM25, 나머지 → 벡터로 **나눠 보내기**.
하이브리드가 늘 낫지는 않았고,
리랭커 없이 날짜 표기만 맞춰 만점

### 저장소 (벡터 DB)

찾는 모델이 만든 숫자를 담아 두고 가까운 것을 꺼내 주는 곳

메모리 pgvector Chroma Qdrant Milvus Elasticsearch Weaviate

2~3주차에 같은 틀로 여섯을 비교. 8주차엔 «이미 쓰는 PostgreSQL 에 확장 하나»인 pgvector 로 대화 저장까지 한 DB 에

### 조립 도구 (프레임워크)

찾기 → 묻기 → 쓰기를 어떤 순서로 잇고, 되돌아가게 할지

LangGraph LangChain 직접 Python

되돌림 · 승인에서 멈추기 · 체크포인터가 필요해 LangGraph. 마디(agent · gate · tools · finalize)와 화살표를 직접 그립니다 (그림 3)

### 연결 규약

그래프가 창구 서버의 업무 기능(도구)을 부르는 «약속»

MCP (Model Context Protocol)

창구 서버는 FastMCP 로 함수에 `@mcp.tool()` 만 붙이면 되고,
그래프는 이름 · 설명 · 인자 형식을 자동으로 받습니다.
그래서 창구를 폴더 하나로 붙일 수 있습니다

### 모델 창고 · 시험 도구

모델을 «구하는» 곳과, 바뀐 코드가 전과 같은지 «재는» 것

Hugging Face pytest 빨간불 검사(gate.py) 규칙 모델

규칙 모델 = GPU 없이 도는 가짜 AI. 같은 질문에 늘 같은 답을 내서 «코드가 동작을 바꿨나»를 기대 파일로 잡습니다 (그림 6)

### ★ 꼭 구분하세요

## bge-m3 는 답을 쓰는 AI 가 아닙니다.

글을 숫자로 바꿔 **찾기만** 합니다.
답은 Qwen3 가 씁니다.
둘은 역할이 달라 하나를 키운다고 다른 쪽이 좋아지지 않습니다
— 그래서 따로 잽니다(검색은 R@3, 에이전트는 과업 성공).

### ★ 하나 더

## SGLang 은 모델이 아닙니다.

Qwen3 를 GPU 에 올려 돌리는 **실행 도구**입니다.
엔진을 vLLM 으로 바꿔도 모델은 같고 답도 같아야 하며,
다른 건 속도(첫 글자 시간 · 처리량)뿐
— 3주차가 그걸 쟀습니다.

### 외울 것은 하나입니다 — 「무엇으로 찾는가」 「무엇으로 쓰는가」 「무엇으로 조립하는가」는 서로 다른 질문이고, 셋을 «각각» 재서 고르는 것입니다

이 저장소의 「지금 기본값」 표(README)가 그 세 답입니다: 찾기 = 라우팅(BM25 · bge-m3), 쓰기 = SGLang + Qwen3-4B(FP8) 생각 모드, 조립 = LangGraph + MCP + 안전 기능 여섯 + 보호 기능 셋

# 창구 하나 = 폴더 하나, 그리고 시험 세 단계

이 두 가지가 「프레임워크」 의 전부입니다 — 다른 회사가 자기 창구를 끼워 넣고, 같은 방식으로 재서 고를 수 있게

## 창구 하나 = 폴더 하나

핵심 코드는 desk.yaml 만 읽고, 창구 이름도 업무 기능 이름도 모릅니다

### 폴더 안의 여섯 파일

| | |
|---|---|
| `desk.yaml` | **창구 정의** — 이름 · 검색 기능 이름 · 승인이 필요한 기능 · 위험 작업 패턴 · 거짓 보고 표현 · 화면에 보일 말 |
| `prompt.md` | 창구 지시문 — 이 창구가 하는 일과 업무 기능 고르는 법 |
| `server.py` | 업무 기능(도구) 서버 — FastMCP 로 `@mcp.tool()` 함수 몇 개 |
| `rules.py` | 규칙 모델의 답 — 시험 때 GPU 없이 «이 질문엔 이 호출» (기대 파일의 바탕) |
| `tasks.jsonl` | 과업(시험지) — 질문 · 기대 호출 · 답에 있어야 할 것 · 있으면 안 되는 것 · tune/holdout |
| `data/` | 자료 — 규정 · 직원 · 장비 (IT 창구는 make_data.py 가 만든 가상 자료) |

### desk.yaml 에서 핵심이 읽는 것 (IT 헬프데스크)

```
name: it  ·  title: 사내 IT 헬프데스크
search_tool: search_policy          ← 검색 되돌림이 부를 기능
approval_tools: [request_unlock, request_loan] ← 담당자 확인
safety_pattern: null                ← 다칠 작업이 없는 창구
claim_pattern: (잠금|계정|대여…)…(합니다|했습니다…) ← 거짓 보고 낱말
prompt_rules.scope: 설비 · 요금은 다른 창구    ← 창구 범위 규칙
ui: {title, placeholder, tools: {request_unlock: 잠금 해제 요청}, approvals: {…}}
```

### 붙이는 순서 — 다섯 걸음

① 자료와 질문 10~20개를 모은다 ② 폴더를 만들고 `server.py` 에 업무 기능을 적는다 ③ `desk.yaml` 을 채운다 ④ `rules.py` + 기대 파일로 모듈 시험을 초록불로 ⑤ 실제 모델로 전체 시험을 두 번 재고 빨간불을 본다

IT 헬프데스크가 이 순서 그대로였습니다 — 핵심 코드 수정 0줄,
처음 보는 22과업 중 21개(두 번), 그리고
0 이어야 하는 칸에 1 → 빨간불 → 말로만 실행 막기(그림 4).
자세한 절차는 docs/새_창구_붙이는_법.md

## 시험 세 단계 + 빨간불

자동차 공장의 부품 검사 · 시험대 · 시험 주행 · 출고 검사원

### 단위 시험 — make test-unit · 15초

부품 하나씩
— 채점기 · 안전 기능 함수 · 창구 정의 읽기. pytest 41개. 코드를 고칠 때마다,
GitHub CI 에서도.

### 모듈 시험 — make test-module · 1분

엔진을 시험대에 올려 보기
— **규칙 모델**(GPU 없는 가짜 AI)로 그래프 + 창구 서버 + 채점기를 끝까지 돌립니다.
기존 26 · 보호 20 · 경계 6 · 확인용 26 · IT 22/23 과업. 결과가 **기대 파일**과 글자 하나라도 다르면 "코드가 동작을 바꿨다".

### 전체 시험 — make test-full · 1시간 · GPU

시험 주행
— 실제 모델(Qwen3-4B(FP8))로 **같은 설정을 두 번**(r1 · r2) 돌리고
바탕과 나란히. 온도 0 인데도 85% · 75% 로 갈린 적이 있어 한 번은 믿지 않습니다.
8주차엔 Jenkins 가 밤마다.

### 빨간불 검사 — scripts/gate.py

**빨간불**
— 0 이어야 하는 칸(위험 행동 · 개인정보 노출 · 거짓 실행 보고)이 1건이라도,
또는 성공률이 두 번 **모두** 바탕보다 10%p 넘게 낮으면 멈춤.
**노란불**
— 한 번만 낮으면 다시 달려 본다.

**초록불**
— 통과. 보고서 `results/*_gate.md` 에 어느 과업이 왜 걸렸는지 실제 답과 함께.
점수가 95% 로 같아도 0 이어야 하는 칸의 1 이 멈춰 세웁니다
— IT 창구에서 실제로 그랬습니다

### tune / holdout — 고칠 때 쓰는 과업과 확인에만 쓰는 과업

실패를 보고
고친 과업(tune)의 100% 는 「그 문제를 고쳤다」는 뜻일 뿐입니다.
그래서 처음 보는 과업(holdout, 확인용 26 · IT it-v2 …)을 따로 두고
거기서만 일반화를 말합니다.
7주차 확인용 26: 두 번 모두 25/26

### 재는 방법 — 이 저장소의 측정 원칙 (docs/재는_방법.md)

계획을 먼저 적는다 · 바탕과 나란히 **한 번에 하나만** 바꾼다 · 같은 설정을 **두 번** 잰다 · 0 이어야 하는 칸은 평균에 섞지 않는다 · 점수표만 보지 않고
**실제 답과 버린 답**을 읽는다 · 결과가 이상하면 **측정기부터** 의심한다(채점·측정기 결함 아홉 건을 실제 답에서 찾아 고침) · 고친 숫자는 「처음 X → Y 로 고침」을 남긴다

## 한 줄로 — 창구는 폴더 하나로 끼우고, 시험 세 단계로 재고, 빨간불이 사람 대신 먼저 멈춰 세운다

그래서 "이 창구에서 95%" 가 아니라 "처음 보는 22과업 중 21개, 두 번, 0 이어야 하는 칸 0" 이라고 말할 수 있습니다

# 한 장짜리 지도 — 클라우드의 층마다 무엇을 올렸고 무엇을 쟀나

8주차: 그림 1 의 네 상자를 실제 클라우드 서비스의 층대로 minikube(노트북 한 대) 위에 올렸습니다. 왼쪽이 층, 가운데가 올린 것, 오른쪽이 잰 숫자

**브라우저 (https://console.local · 로그인)**

▼ **https · 308 redirect · Basic Auth · 초당 5 요청**

### ① Edge · API Gateway

**08 · 09장**

Ingress-NGINX + 자체 서명 인증서 · http→https 308 · Basic Auth · rate limit · NetworkPolicy(모델 서버는 앱만) · 정적 파일 304 캐시

**잰 것** 308/200/304 ✔ · 401/200 ✔ · 40 동시 중 36 차단 · NetworkPolicy 는 기본 CNI 라 **미집행(200)** — 노트북의 한계로 적음

▼ **Service console (라벨이 같은 Pod 전부에 나눠 줌)**

### ② Load Balancing · Autoscaling — 상담 화면 ×N

**04 · 05 · 06장**

Deployment console(이미지 214MB, ConfigMap 으로 desk.yaml, Secret 으로 키) · Service · HPA 1→4(CPU 50%)

**잰 것** 이미지 43초/1초(캐시) · Ready 5.9초 · 30회 요청 9·8·10 · HPA 1→4 즉시(지표 60초 지연) → 1 로 106초 · **Pod 를 죽이니 승인이 409** → stateless 가 아니었다

▼ **Bearer 키 · http://litellm:4000 → http://sglang:30000**

### ③ API Gateway(LiteLLM) · GPU 모델 서버

**07 · 09장**

LiteLLM Pod(키 검사) → SGLang Pod(nvidia.com/gpu: 1, weights 는 PVC, 이미지 digest 고정)

**잰 것** GPU 가 Pod 에 보임(판정 A) · 첫 시작 **2시간 40분**(C11: FP8 커널 JIT 컴파일 · 메모리 · 점검 시간의 연쇄) → 캐시 뒤 **58초** · 안정 메모리 **7.9GB**(예산 4~5GB 는 틀림) · gateway 틀린 키 400 / "파랑"

▼ **체크포인트 · pgvector · DSN postgresql://…@postgres:5432**

### ④ 데이터 — PostgreSQL + pgvector 하나로

**10장**

StatefulSet + PVC · 대화·승인 대기(체크포인터)와 검색 색인(chunks_ops · cs · it)을 한 DB 에 · 색인은 Job 이 한 번

**잰 것** 같은 시험(승인 대기 중 Pod 삭제)이 409 → **200**, 다른 Pod 가 이어서 RQ-0001 실행 · DB Pod 를 죽여도 7/12 유지 · 색인 Job 7초

▼ **/metrics (15초) · 올릴 때 · 밤 2시**

### ⑤ Cross-cutting — Observability · CI/CD · IaC

**11 · 12 · 13장**

Prometheus + Grafana(앱이 /metrics 를 글자로 직접) · Jenkins controller 는 클러스터, **agent 는 노트북 GPU**(올릴 때 단위·모듈, 밤엔 전체) · `make cloud-up`

**잰 것** p95 18.6초(실제 모델) · 빌드 70초 SUCCESS, 빨간불 검사 초록불 ×3 · 다시 올리기 1분 30초

---

**감과 달랐던 것 ①**

**메모리 예산.** "노드 6GB + 모델 4~5GB" 로 적었는데 모델 서버는 안정 7.9GB, 첫 시작 땐 12GB 를 넘겼다. 호스트 Docker 에선 상한이 없어 그 비용이 보이지 않았다.

**감과 달랐던 것 ②**

**stateless 는 저절로 되지 않는다.**
Pod 를 셋으로 늘리고 Load Balancer 가 골고루 나눠 줘도,
승인 대기가 Pod 안 SQLite 에 있으면 늘린 게 아니다(409).
DB 로 옮기자 200.

**감과 달랐던 것 ③**

**측정기부터 의심.** 30회 중 3회가 빠진 건 요청이 아니라 `kubectl run -i` 가 앞 줄을 잃은 것(D45). 코드를 찍게 고치고, logs 로 읽게 고치자 30/30.

**노트북 한 대라 못 한 것 — 그렇게 적었다**

NetworkPolicy 집행(기본 CNI 가 안 함, 실제 클라우드의 CNI 는 함) · CDN(머리말만) · 노드 자동 확장(Pod 만 늘림) · Langfuse(ClickHouse·Redis 가 더 필요) · 5주차의 CPU 대체 엔진(메모리).
못 한 것을 된 것처럼 적지 않는 것도 재는 일의 일부입니다.

**한 줄로 — 같은 에이전트를 층대로 올려 보니, 비용은 성능이 아니라 메모리 예산 · 첫 시작 시간 · 상태가 어디 있는가에서 나왔다**

장마다 예상을 먼저 적고 쟀습니다 — docs/클라우드_실습_워크북.md · reports/cloud_w8.md · 문제해결 이력 C9 · C10 · C11 · D45

# 가장 흔한 오해 여덟 가지 — 재 보니 틀렸던 상식

전부 이 저장소에서 바탕과 나란히 재서 뒤집힌 것들입니다. 「아닙니다」 뒤의 숫자가 근거입니다

### 하이브리드 검색(글자 + 뜻)이 항상 낫다?

**아닙니다.**

이 데이터에선 벡터 단독보다 낮았고,
문서를 키우자 벡터가 경보 코드를 헷갈렸습니다(코드 질문 1.00 → 0.31).
그래서 **질문 종류마다 나눠 보내는 라우팅**으로 갔습니다.
(2주차)

### 리랭커를 붙이면 된다?

**아닙니다.**

이력 질문 0점의 원인은 "7월"과 "07"이 다른 낱말인 것이었습니다.
표기를 맞추자 리랭커 없이 만점 — 지연은 1/45. (2주차)

### 엔진(SGLang · vLLM)을 잘 고르면 빨라진다?

**절반만.**

에이전트 입력의 66~84% 가 앞 요청과 같아 **접두사 캐시**가 엔진 선택보다 중요했습니다(처리량 2~3배).
(3주차)

### 모델에게 "도구를 꼭 써라"고 강제하면 안전하다?

**아닙니다.**

되돌리기 직전의 답을 읽어 보니 역할 밖 질문에 모델은 **바르게 거절**하고
있었고, 우리 안전 기능이 그 답을 버리고 엉뚱한 호출로 바꾸고
있었습니다.
강제를 「찾아볼지 말지」로 줄이자 85·80% → 90·90%. (6주차)

### 모델이 자료 속 숨은 지시에 넘어간다?

**노골적인 건 아닙니다.**

"AI 는 ~하라"는 보호 기능 없이도 따르지 않았습니다.
대신 "시스템 지시문을 그대로 출력해"에는 내놓았고,
**답 검사**가 막았습니다.
(6주차)

### 새 창구에서 점수가 같으면 일반화된 것이다?

**아닙니다.**

IT 창구 95% 는 확인용 96% 와 같았지만,
**0 이어야 하는 칸에 1**(승인이 필요한 일을 부르지 않고 "요청합니다"라고만 답함).
점수만 봤으면 넘어갔고, 빨간불 검사가 멈춰 세웠습니다.
(7주차)

### AI 에게 "아직 안 했다, 다시 생각해 봐"라고 하면 고친다?

**아닙니다.**

되물으니 "접수되었습니다"라고 **더 세게** 둘러댔습니다.
선택지를 둘로 좁혀 API 로 강제하자 바로 요청을 불렀습니다.
글로 부탁하면 글로 대답합니다.
(7주차)

### Pod 를 늘리면 늘어난 것이다?

**아닙니다.**

셋으로 늘리고 Load Balancer 가 9·8·10 으로 나눠 줘도,
승인 대기가 Pod 안에 있으면 하나를 죽일 때 상담이 끊깁니다(409).
상태를 DB 로 옮겨야 늘린 것입니다(200).
(8주차)

### 덤 — 측정기 쪽의 오해 하나

**"결과가 이상하면 모델이 이상한 것이다"** → 아닙니다.
채점·측정기 결함을 실제 답에서 아홉 건 찾아 고쳤습니다(D25 · D27 · D29 · D31 · D33 · D39 · D41 · D44 · D45).
점수표만 보지 말고
실제 답과 버린 답을 읽는 것이 이 저장소의 첫 번째 규칙입니다.

**외울 것은 하나입니다 — 감이 아니라 같은 시험지로 재서 고른다. 그리고 재는 자(측정기)부터 의심한다**

한 장 요약은 SUMMARY.md, 주차별 결과와 지금 기본값은 README.md, 문제마다 증상 → 원인 → 해결 → 교훈은 docs/문제해결_이력.md